

# Algoritmos Basados en Poblaciones

Jose Antonio Lozano

Intelligent Systems Group

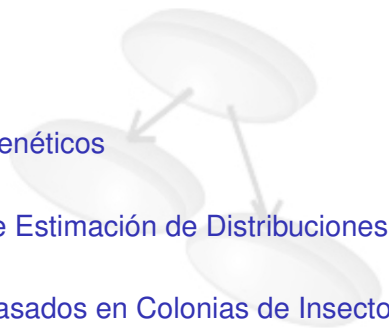
Departamento de Ciencias de la Computación e Inteligencia Artificial

Universidad del País Vasco–Euskal Herriko Unibertsitatea




UPV - EHU

# Organización del tema

- 
- 1 Introducción
  - 2 Algoritmos Genéticos
  - 3 Algoritmos de Estimación de Distribuciones
  - 4 Algoritmos Basados en Colonias de Insectos
  - 5 Búsqueda Dispersa

# Organización del tema

- 
- 1 **Introducción**
  - 2 Algoritmos Genéticos
  - 3 Algoritmos de Estimación de Distribuciones
  - 4 Algoritmos Basados en Colonias de Insectos
  - 5 Búsqueda Dispersa

# Algoritmos poblacionales

## Características

- A cada paso del algoritmo mantienen un **conjunto** de soluciones (*población*)
- Algoritmos inspirados en la naturaleza
- Pueden utilizar métodos de búsqueda local
- Cuestión clave: ¿cómo sacar provecho de las poblaciones?



# Organización del tema

- 
- 1 Introducción
- 2 Algoritmos Genéticos**
- 3 Algoritmos de Estimación de Distribuciones
- 4 Algoritmos Basados en Colonias de Insectos
- 5 Búsqueda Dispersa

# Computación evolutiva

## Ideas básicas

- Un conjunto de técnicas computacionales basadas en *imitar* el proceso de evolución de las especies en el mundo natural siguiendo los postulados de Darwin
- Engloba diferentes paradigmas estando la mayoría de ellos dedicados a la optimización
- Sus comienzos datan de los 60 y los 70 siendo las referencias más relevantes: Holland (1975), Goldberg (1989), Schwefel (1981), Fogel (1962,1964)



# Computación evolutiva

## Ideas básicas

- Un conjunto de técnicas computacionales basadas en *imitar* el proceso de evolución de las especies en el mundo natural siguiendo los postulados de Darwin
- Engloba diferentes paradigmas estando la mayoría de ellos dedicados a la optimización
- Sus comienzos datan de los 60 y los 70 siendo las referencias más relevantes: Holland (1975), Goldberg (1989), Schwefel (1981), Fogel (1962,1964)



# Computación evolutiva

## Ideas básicas

- Un conjunto de técnicas computacionales basadas en *imitar* el proceso de evolución de las especies en el mundo natural siguiendo los postulados de Darwin
- Engloba diferentes paradigmas estando la mayoría de ellos dedicados a la optimización
- Sus comienzos datan de los 60 y los 70 siendo las referencias más relevantes: Holland (1975), **Goldberg (1989)**, Schwefel (1981), Fogel (1962,1964)





# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Características y algoritmos

## Características principales

- Uso de un conjunto de soluciones a cada paso: **población**
- Se generan nuevas soluciones combinando y modificando las actuales mediante el uso de operadores:
  - **Selección** de los mejores
  - Operadores de reproducción: **cruce** y **mutación**

## Algoritmos principales

- Algoritmos genéticos
- Estrategias evolutivas-Programación evolutiva
- Programación genética



# Algoritmos genéticos

## Esquema básico

- Cada solución al problema se denomina **individuo** o **cromosoma** y se representa mediante una cadena binaria
- A cada paso se mantiene un conjunto de soluciones denominado **población**
- Se aplican tres operadores evolutivos: **selección**, **cruce** y **mutación**
- La población en el tiempo  $t$  se sustituye por la población en el tiempo  $t + 1$





# Algoritmos genéticos

## Esquema básico

- Cada solución al problema se denomina **individuo** o **cromosoma** y se representa mediante una cadena binaria
- A cada paso se mantiene un conjunto de soluciones denominado **población**
- Se aplican tres operadores evolutivos: **selección**, **cruce** y **mutación**
- La población en el tiempo  $t$  se sustituye por la población en el tiempo  $t + 1$



# Algoritmos genéticos

## Esquema básico

- Cada solución al problema se denomina **individuo** o **cromosoma** y se representa mediante una cadena binaria
- A cada paso se mantiene un conjunto de soluciones denominado **población**
- Se aplican tres operadores evolutivos: **selección**, **cruce** y **mutación**
- La población en el tiempo  $t$  se sustituye por la población en el tiempo  $t + 1$



# Algoritmos genéticos

## Esquema básico

- Cada solución al problema se denomina **individuo** o **cromosoma** y se representa mediante una cadena binaria
- A cada paso se mantiene un conjunto de soluciones denominado **población**
- Se aplican tres operadores evolutivos: **selección**, **cruce** y **mutación**
- La población en el tiempo  $t$  se sustituye por la población en el tiempo  $t + 1$



# Pseudocódigo

Hallar la población inicial  $P_0$

**hasta** condición\_parada = TRUE **hacer**

**repetir**  $\frac{n}{2}$  **veces**

    Elegir aleatoriamente dos individuos de la población  $P_k$

    Cruzar los dos individuos con probabilidad  $p_c$

    Mutar los dos individuos resultantes con probabilidad  $p_m$

    Introducir los dos nuevos individuos en la población  $P'_k$

  Seleccionar  $n$  individuos de  $P'_k$  para obtener  $P_{k+1}$

Devolver la mejor solución

# Cruce basado en un punto



# Operador de mutación

- Cada bit modifica su valor con una probabilidad  $p_m$

1	0	1	0	0	0	0	1	0
---	---	---	---	---	---	---	---	---



1	0	0	1	0	0	0	0	0
---	---	---	---	---	---	---	---	---

# Operador de selección

## Selección proporcional al valor de función objetivo

- Los individuos se seleccionan de forma aleatoria
- La probabilidad de seleccionar un individuo  $x$  es:

$$p_{sel}(x) = \frac{f(x)}{\sum_{y \in P_t} f(y)}$$

# Operador de selección

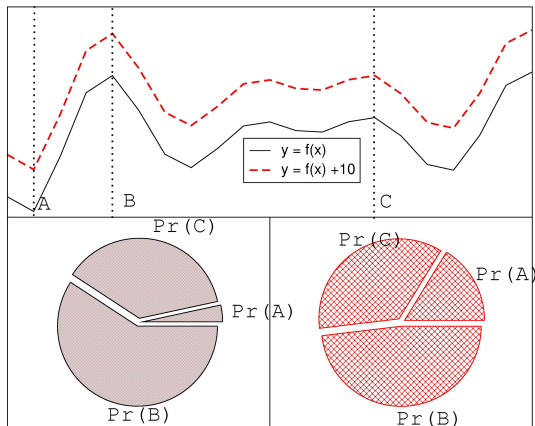
## Selección proporcional al valor de función objetivo

- Los individuos se seleccionan de forma aleatoria
- La probabilidad de seleccionar un individuo  $x$  es:

$$p_{sel}(x) = \frac{f(x)}{\sum_{y \in P_t} f(y)}$$



# Operador de selección



# Ejemplo de aplicación

*Ejemplo:* Máximo de  $f(x) = x^2$  sobre los enteros  $\{1, 2, \dots, 32\}$

	Población inicial (fenotipos)	$x$ valor genotipo	$f(x)$ valor (función adaptación)	$f(x) / \sum f(x)$ (probabilidad selección)	Probabilidad de selección acumulada
1	01101	13	169	0.14	0.14
2	11000	24	576	0.49	0.63
3	01000	8	64	0.06	0.69
4	10011	19	361	0.31	1.00
Suma			1170		
Media			293		
Mejor			576		

# Ejemplo de aplicación

Emparejamiento de los individuos seleccionados	Punto de cruce	Descendientes	Nueva población descendientes mutados	x valor genotipo	$f(x)$ función adaptación
11000	2	11011	11011	27	729
10011	2	10000	10000	16	256
01101	3	01100	11100	28	784
11000	3	11001	11101	29	841
Suma					2610
Media					652.5
Mejor					841

# Extensiones y modificaciones del algoritmo genético simple

## Extensiones

- **Codificación: numéricas, reales, permutaciones**
- Operadores de selección: torneo, truncación, Boltzmann, elitismo
- Operadores de cruce: basado en  $n$  puntos, uniforme, específicos para el problema y la codificación



# Extensiones y modificaciones del algoritmo genético simple

## Extensiones

- Codificación: numéricas, reales, permutaciones
- Operadores de selección: torneo, truncación, Boltzmann, elitismo
- Operadores de cruce: basado en  $n$  puntos, uniforme, específicos para el problema y la codificación

# Extensiones y modificaciones del algoritmo genético simple

## Extensiones

- Codificación: numéricas, reales, permutaciones
- Operadores de selección: torneo, truncación, Boltzmann, elitismo
- Operadores de cruce: basado en  $n$  puntos, uniforme, específicos para el problema y la codificación



# Aplicación de los algoritmos genéticos

## Aspectos a determinar para resolver un problema mediante algoritmos genéticos

- **Codificación más adecuada**
- Generación de la población inicial
- Operadores a utilizar
- Valores para los parámetros: tamaño de la población, probabilidad de cruce, probabilidad de mutación, criterio de parada

# Aplicación de los algoritmos genéticos

## Aspectos a determinar para resolver un problema mediante algoritmos genéticos

- Codificación más adecuada
- Generación de la población inicial
- Operadores a utilizar
- Valores para los parámetros: tamaño de la población, probabilidad de cruce, probabilidad de mutación, criterio de parada





# Aplicación de los algoritmos genéticos

## Aspectos a determinar para resolver un problema mediante algoritmos genéticos

- Codificación más adecuada
- Generación de la población inicial
- Operadores a utilizar
- Valores para los parámetros: tamaño de la población, probabilidad de cruce, probabilidad de mutación, criterio de parada

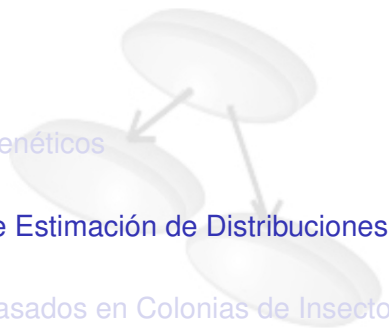
# Aplicación de los algoritmos genéticos

## Aspectos a determinar para resolver un problema mediante algoritmos genéticos

- Codificación más adecuada
- Generación de la población inicial
- Operadores a utilizar
- Valores para los parámetros: tamaño de la población, probabilidad de cruce, probabilidad de mutación, criterio de parada



# Organización del tema

- 
- 1 Introducción
  - 2 Algoritmos Genéticos
  - 3 Algoritmos de Estimación de Distribuciones**
  - 4 Algoritmos Basados en Colonias de Insectos
  - 5 Búsqueda Dispersa

# Introducción a los EDAs

## Características de los EDAs

- Algoritmos de optimización basados en **poblaciones**
- Se eliminan los operadores de reproducción de un algoritmo genético:
  - Se **aprende** una distribución de probabilidad a partir de los individuos seleccionados
  - Se **muestrea** la distribución aprendida para obtener la nueva población

# Introducción a los EDAs

## Características de los EDAs

- Algoritmos de optimización basados en **poblaciones**
- Se eliminan los operadores de reproducción de un algoritmo genético:
  - Se **aprende** una distribución de probabilidad a partir de los individuos seleccionados
  - Se **muestrea** la distribución aprendida para obtener la nueva población



# Introducción a los EDAs

## Características de los EDAs

- Algoritmos de optimización basados en **poblaciones**
- Se eliminan los operadores de reproducción de un algoritmo genético:
  - Se **aprende** una distribución de probabilidad a partir de los individuos seleccionados
  - Se **muestra** la distribución aprendida para obtener la nueva población

# Introducción a los EDAs

## Características de los EDAs

- Algoritmos de optimización basados en **poblaciones**
- Se eliminan los operadores de reproducción de un algoritmo genético:
  - Se **aprende** una distribución de probabilidad a partir de los individuos seleccionados
  - Se **muestrea** la distribución aprendida para obtener la nueva población

# Un ejemplo sencillo

## Optimización de OneMax con EDAs

$$\max f(\mathbf{x}) = \sum_{i=1}^6 x_i$$

con  $x_i = 0, 1$



# Un ejemplo sencillo

## Optimización de OneMax con EDAs

$$\max f(\mathbf{x}) = \sum_{i=1}^6 x_i$$

con  $x_i = 0, 1$

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$f(\mathbf{x})$
1	1	0	1	0	1	0	3
2	0	1	0	0	1	0	2
3	0	0	0	1	0	0	1
4	1	1	1	0	0	1	4
5	0	0	0	0	0	1	1
6	1	1	0	0	1	1	4
7	0	1	1	1	1	1	5
8	0	0	0	1	0	0	1
9	1	1	0	1	0	0	3
10	1	0	1	0	0	0	2
11	1	0	0	1	1	1	4
12	1	1	0	0	0	1	3
13	1	0	1	0	0	0	2
14	0	0	0	0	1	1	2
15	0	1	1	1	1	1	5
16	0	0	0	1	0	0	1
17	1	1	1	1	1	0	5
18	0	1	0	1	1	0	3
19	1	0	1	1	1	1	5
20	1	0	1	1	0	0	3



# Un ejemplo sencillo

## Optimización de OneMax con EDAs

$$\max f(\mathbf{x}) = \sum_{i=1}^6 x_i$$

con  $x_i = 0, 1$

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$f(\mathbf{x})$
1	1	0	1	0	1	0	3
2	0	1	0	0	1	0	2
3	0	0	0	1	0	0	1
4	1	1	1	0	0	1	4
5	0	0	0	0	0	1	1
6	1	1	0	0	1	1	4
7	0	1	1	1	1	1	5
8	0	0	0	1	0	0	1
9	1	1	0	1	0	0	3
10	1	0	1	0	0	0	2
11	1	0	0	1	1	1	4
12	1	1	0	0	0	1	3
13	1	0	1	0	0	0	2
14	0	0	0	0	1	1	2
15	0	1	1	1	1	1	5
16	0	0	0	1	0	0	1
17	1	1	1	1	1	0	5
18	0	1	0	1	1	0	3
19	1	0	1	1	1	1	5
20	1	0	1	1	0	0	3



# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
1	1	0	1	0	1	0
4	1	1	1	0	0	1
6	1	1	0	0	1	1
7	0	1	1	1	1	1
11	1	0	0	1	1	1
12	1	1	0	0	0	1
15	0	1	1	1	1	1
17	1	1	1	1	1	0
18	0	1	0	1	1	0
19	1	0	1	1	1	1

# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
1	1	0	1	0	1	0
4	1	1	1	0	0	1
6	1	1	0	0	1	1
7	0	1	1	1	1	1
11	1	0	0	1	1	1
12	1	1	0	0	0	1
15	0	1	1	1	1	1
17	1	1	1	1	1	0
18	0	1	0	1	1	0
19	1	0	1	1	1	1

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
1	1	0	1	0	1	0
4	1	1	1	0	0	1
6	1	1	0	0	1	1
7	0	1	1	1	1	1
11	1	0	0	1	1	1
12	1	1	0	0	0	1
15	0	1	1	1	1	1
17	1	1	1	1	1	0
18	0	1	0	1	1	0
19	1	0	1	1	1	1

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10}$$



# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
1	1	0	1	0	1	0
4	1	1	1	0	0	1
6	1	1	0	0	1	1
7	0	1	1	1	1	1
11	1	0	0	1	1	1
12	1	1	0	0	0	1
15	0	1	1	1	1	1
17	1	1	1	1	1	0
18	0	1	0	1	1	0
19	1	0	1	1	1	1

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10}$$

$$p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
1	1	0	1	0	1	0
4	1	1	1	0	0	1
6	1	1	0	0	1	1
7	0	1	1	1	1	1
11	1	0	0	1	1	1
12	1	1	0	0	0	1
15	0	1	1	1	1	1
17	1	1	1	1	1	0
18	0	1	0	1	1	0
19	1	0	1	1	1	1

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10}$$

$$p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10} \quad p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$





# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10} \quad p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

$$p(X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1)$$

# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10} \quad p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

$$p(X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1) =$$

$$p(X_1 = 1) \cdot p(X_2 = 0) \cdot p(X_3 = 1) \cdot p(X_4 = 0) \cdot p(X_5 = 1) \cdot p(X_6 = 1) =$$



# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10} \quad p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

$$p(X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1) =$$

$$p(X_1 = 1) \cdot p(X_2 = 0) \cdot p(X_3 = 1) \cdot p(X_4 = 0) \cdot p(X_5 = 1) \cdot p(X_6 = 1) =$$

↓

$$\frac{7}{10} \cdot \quad \cdot \quad \cdot \quad \cdot \quad \cdot$$



# Un ejemplo sencillo

## Aprendiendo la distribución de probabilidad

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$p(X_1 = 1) = \frac{7}{10} \quad p(X_2 = 1) = \frac{7}{10} \quad p(X_3 = 1) = \frac{6}{10} \quad p(X_4 = 1) = \frac{6}{10} \quad p(X_5 = 1) = \frac{8}{10} \quad p(X_6 = 1) = \frac{7}{10}$$

$$p(X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1) =$$

$$p(X_1 = 1) \cdot p(X_2 = 0) \cdot p(X_3 = 1) \cdot p(X_4 = 0) \cdot p(X_5 = 1) \cdot p(X_6 = 1) =$$

$$\begin{array}{ccccccccc} \downarrow & & \downarrow & & \downarrow & & \downarrow & & \downarrow & & \downarrow \\ \frac{7}{10} & \cdot & \frac{3}{10} & \cdot & \frac{6}{10} & \cdot & \frac{4}{10} & \cdot & \frac{8}{10} & \cdot & \frac{7}{10} \end{array}$$

# Un ejemplo sencillo

## Obteniendo la nueva población

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$0.23 \quad p(X_1 = 1) = \frac{7}{10} \longrightarrow 1$$

$$0.85 \quad p(X_2 = 1) = \frac{7}{10} \longrightarrow 0$$

$$0.89 \quad p(X_3 = 1) = \frac{6}{10} \longrightarrow 0$$

$$0.12 \quad p(X_4 = 1) = \frac{6}{10} \longrightarrow 1$$

$$0.98 \quad p(X_5 = 1) = \frac{8}{10} \longrightarrow 0$$

$$0.54 \quad p(X_6 = 1) = \frac{7}{10} \longrightarrow 1$$



# Un ejemplo sencillo

## Obteniendo la nueva población

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$0.23 \quad p(X_1 = 1) = \frac{7}{10} \longrightarrow 1$$

$$0.85 \quad p(X_2 = 1) = \frac{7}{10} \longrightarrow 0$$

$$0.89 \quad p(X_3 = 1) = \frac{6}{10} \longrightarrow 0$$

$$0.12 \quad p(X_4 = 1) = \frac{6}{10} \longrightarrow 1$$

$$0.98 \quad p(X_5 = 1) = \frac{8}{10} \longrightarrow 0$$

$$0.54 \quad p(X_6 = 1) = \frac{7}{10} \longrightarrow 1$$



# Un ejemplo sencillo

## Obteniendo la nueva población

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$0.23 \quad p(X_1 = 1) = \frac{7}{10} \longrightarrow 1$$

$$0.85 \quad p(X_2 = 1) = \frac{7}{10} \longrightarrow 0$$

$$0.89 \quad p(X_3 = 1) = \frac{6}{10} \longrightarrow 0$$

$$0.12 \quad p(X_4 = 1) = \frac{6}{10} \longrightarrow 1$$

$$0.98 \quad p(X_5 = 1) = \frac{8}{10} \longrightarrow 0$$

$$0.54 \quad p(X_6 = 1) = \frac{7}{10} \longrightarrow 1$$



# Un ejemplo sencillo

## Obteniendo la nueva población

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$0.23 \quad p(X_1 = 1) = \frac{7}{10} \longrightarrow 1$$

$$0.85 \quad p(X_2 = 1) = \frac{7}{10} \longrightarrow 0$$

$$0.89 \quad p(X_3 = 1) = \frac{6}{10} \longrightarrow 0$$

$$0.12 \quad p(X_4 = 1) = \frac{6}{10} \longrightarrow 1$$

$$0.98 \quad p(X_5 = 1) = \frac{8}{10} \longrightarrow 0$$

$$0.54 \quad p(X_6 = 1) = \frac{7}{10} \longrightarrow 1$$





# Un ejemplo sencillo

## Obteniendo la nueva población

$$p(\mathbf{x}) = p(x_1, \dots, x_6) = p(x_1) \cdot p(x_2) \cdot p(x_3) \cdot p(x_4) \cdot p(x_5) \cdot p(x_6)$$

$$0.23 \quad p(X_1 = 1) = \frac{7}{10} \longrightarrow 1$$

$$0.85 \quad p(X_2 = 1) = \frac{7}{10} \longrightarrow 0$$

$$0.89 \quad p(X_3 = 1) = \frac{6}{10} \longrightarrow 0$$

$$0.12 \quad p(X_4 = 1) = \frac{6}{10} \longrightarrow 1$$

$$0.98 \quad p(X_5 = 1) = \frac{8}{10} \longrightarrow 0$$

$$0.54 \quad p(X_6 = 1) = \frac{7}{10} \longrightarrow 1$$



# Un ejemplo sencillo

## Obteniendo la nueva población

	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$	$f(\mathbf{x})$
1	1	1	0	1	0	1	5
2	1	0	1	0	1	1	4
3	1	1	1	1	1	0	5
4	0	1	0	1	1	1	4
5	1	1	1	1	0	1	5
6	1	0	0	1	1	1	4
7	0	1	0	1	1	0	3
8	1	1	1	0	1	0	4
9	1	1	1	0	0	1	4
10	1	0	0	1	1	1	4
11	1	1	0	0	1	1	4
12	1	0	1	1	1	0	4
13	0	1	1	0	1	1	4
14	0	1	1	1	1	0	4
15	1	1	1	1	1	1	6
16	0	1	1	0	1	1	4
17	1	1	1	1	1	0	5
18	0	1	0	0	1	0	2
19	0	0	1	1	0	1	3
20	1	1	0	1	1	1	5



# Pseudocódigo para los EDAs

Obtener una población inicial de individuos  $D_0$

**Repetir** hasta que se cumpla un criterio de parada

*Seleccionar de  $D_i$  un conjunto de individuos  $D_i^S$*

*Aprender una distribución de prob.  $p_i(\mathbf{x})$  a partir de  $D_i^S$*

*Muestrear  $p_i(\mathbf{x})$  para obtener  $D_{i+1/2}$*

*Crear la nueva población  $D_{i+1}$  a partir de  $D_i$  y  $D_{i+1/2}$*

# Diseño de un EDA

¿Qué componentes hay que establecer en los EDAs?

- **Tamaño de población**
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad

# Diseño de un EDA

¿Qué componentes hay que establecer en los EDAs?

- Tamaño de población
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad



# Diseño de un EDA

¿Qué componentes hay que establecer en los EDAs?

- Tamaño de población
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad

# Diseño de un EDA

## ¿Qué componentes hay que establecer en los EDAs?

- Tamaño de población
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad

# Diseño de un EDA

¿Qué componentes hay que establecer en los EDAs?

- Tamaño de población
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad





# Diseño de un EDA

## ¿Qué componentes hay que establecer en los EDAs?

- Tamaño de población
- Criterio de selección
- Determinación del modelo probabilístico a utilizar
- Algoritmo de aprendizaje de la distribución de probabilidad
- Algoritmo de muestreo de la distribución de probabilidad



# Algunas ideas generales

## ¿Por qué surgen los EDAs?

- Pésimo comportamiento de los AGs en algunos problemas sencillos (*deceptive*, separables)
- Necesidad de diseñar muchos componentes y establecer el valor de muchos parámetros
- Extender los AGs de cara a considerar interacciones entre las variables (generalización de los AGs)



# Algunas ideas generales

## ¿Por qué surgen los EDAs?

- Pésimo comportamiento de los AGs en algunos problemas sencillos (*deceptive*, separables)
- Necesidad de diseñar muchos componentes y establecer el valor de muchos parámetros
- Extender los AGs de cara a considerar interacciones entre las variables (generalización de los AGs)



# Algunas ideas generales

## ¿Por qué surgen los EDAs?

- Pésimo comportamiento de los AGs en algunos problemas sencillos (*deceptive*, separables)
- Necesidad de diseñar muchos componentes y establecer el valor de muchos parámetros
- Extender los AGs de cara a considerar interacciones entre las variables (generalización de los AGs)



# Clasificación de los EDAs

## Varias clasificaciones

- Basada en si la **estructura del modelo** se mantiene fija a lo largo de todo el algoritmo o no
- Basada en el **tipo de dependencias** que consideran los modelos probabilísticos utilizados

# Clasificación de los EDAs

## Varias clasificaciones

- Basada en si la **estructura del modelo** se mantiene fija a lo largo de todo el algoritmo o no
- Basada en el **tipo de dependencias** que consideran los modelos probabilísticos utilizados

## Clasificación en función de las dependencias

- Algoritmos que suponen que las variables son independientes
- Algoritmos que consideran relaciones de orden dos entre las variables
- Algoritmos que no restringen las relaciones entre las variables



## Clasificación en función de las dependencias

- Algoritmos que suponen que las variables son independientes
- Algoritmos que consideran relaciones de orden dos entre las variables
- Algoritmos que no restringen las relaciones entre las variables



## Clasificación en función de las dependencias

- Algoritmos que suponen que las variables son independientes
- Algoritmos que consideran relaciones de orden dos entre las variables
- Algoritmos que no restringen las relaciones entre las variables



# Univariate Marginal Distribution Algorithm (UMDA)

Obtener una población inicial de individuos  $D_0$

**Repetir** hasta que se cumpla un criterio de parada

*Seleccionar de  $D_l$  un conjunto de individuos  $D_l^S$*

*Aprender una distribución de prob.:*

$$p_l(\mathbf{x}) = p(\mathbf{x}|D_l^S) = \prod_{i=1}^n p_l(x_i) = \prod_{i=1}^n \frac{\sum_{j=1}^N \delta_j(X_j=x_i|D_l^S)}{N} \text{ a}$$

*partir de  $D_l^S$*

*Muestrear  $p_l(\mathbf{x})$  para obtener  $D_{l+1/2}$*

*Crear la nueva población  $D_{l+1}$  a partir de  $D_l$  y  $D_{l+1/2}$*



# Univariate Marginal Distribution Algorithm (UMDA)

Obtener una población inicial de individuos  $D_0$

**Repetir** hasta que se cumpla un criterio de parada

*Seleccionar de  $D_l$  un conjunto de individuos  $D_l^S$*

*Aprender una distribución de prob.:*

$$p_l(\mathbf{x}) = p(\mathbf{x}|D_l^S) = \prod_{i=1}^n p_l(x_i) = \prod_{i=1}^n \frac{\sum_{j=1}^N \delta_j(X_j=x_i|D_l^S)}{N} \quad a$$

*partir de  $D_l^S$*

*Muestrear  $p_l(\mathbf{x})$  para obtener  $D_{l+1/2}$*

*Crear la nueva población  $D_{l+1}$  a partir de  $D_l$  y  $D_{l+1/2}$*

# Population Based Incremental Learning (PBIL)

Obtener un vector de probabilidad inicial  $p_0(\mathbf{x})$

**while** no convergencia **do**  
**begin**

Usando  $p_l(\mathbf{x})$  obtener  $M$  individuos:  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Evaluar y ordenar  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Seleccionar los  $N$  ( $N \leq M$ ) mejores individuos:  $\mathbf{x}'_{1:M}, \dots, \mathbf{x}'_{k:M}, \dots, \mathbf{x}'_{N:M}$

Actualizar el vector de probabilidades  $p_{l+1}(\mathbf{x}) = (p_{l+1}(x_1), \dots, p_{l+1}(x_n))$

**for**  $i = 1, \dots, n$  **do**

$$p_{l+1}(x_i) = (1 - \alpha)p_l(x_i) + \alpha \frac{1}{N} \sum_{k=1}^N x'_{i,k:M}$$

**end**



# Population Based Incremental Learning (PBIL)

Obtener un vector de probabilidad inicial  $p_0(\mathbf{x})$

**while** no convergencia **do**  
**begin**

Usando  $p_l(\mathbf{x})$  obtener  $M$  individuos:  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Evaluar y ordenar  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Seleccionar los  $N$  ( $N \leq M$ ) mejores individuos:  $\mathbf{x}'_{1:M}, \dots, \mathbf{x}'_{k:M}, \dots, \mathbf{x}'_{N:M}$

Actualizar el vector de probabilidades  $p_{l+1}(\mathbf{x}) = (p_{l+1}(x_1), \dots, p_{l+1}(x_n))$

**for**  $i = 1, \dots, n$  **do**

$$p_{l+1}(x_i) = (1 - \alpha)p_l(x_i) + \alpha \frac{1}{N} \sum_{k=1}^N x'_{i,k:M}$$

**end**



# Population Based Incremental Learning (PBIL)

Obtener un vector de probabilidad inicial  $p_0(\mathbf{x})$

**while** no convergencia **do**  
**begin**

Usando  $p_l(\mathbf{x})$  obtener  $M$  individuos:  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Evaluar y ordenar  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Seleccionar los  $N$  ( $N \leq M$ ) mejores individuos:  $\mathbf{x}'_{1:M}, \dots, \mathbf{x}'_{k:M}, \dots, \mathbf{x}'_{N:M}$

Actualizar el vector de probabilidades  $p_{l+1}(\mathbf{x}) = (p_{l+1}(x_1), \dots, p_{l+1}(x_n))$

**for**  $i = 1, \dots, n$  **do**

$$p_{l+1}(x_i) = (1 - \alpha)p_l(x_i) + \alpha \frac{1}{N} \sum_{k=1}^N x'_{i,k:M}$$

**end**



# Population Based Incremental Learning (PBIL)

Obtener un vector de probabilidad inicial  $p_0(\mathbf{x})$

**while** no convergencia **do**  
**begin**

Usando  $p_l(\mathbf{x})$  obtener  $M$  individuos:  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Evaluar y ordenar  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Seleccionar los  $N$  ( $N \leq M$ ) mejores individuos:  $\mathbf{x}'_{1:M}, \dots, \mathbf{x}'_{k:M}, \dots, \mathbf{x}'_{N:M}$

Actualizar el vector de probabilidades  $p_{l+1}(\mathbf{x}) = (p_{l+1}(x_1), \dots, p_{l+1}(x_n))$

**for**  $i = 1, \dots, n$  **do**

$$p_{l+1}(x_i) = (1 - \alpha)p_l(x_i) + \alpha \frac{1}{N} \sum_{k=1}^N x'_{i,k:M}$$

**end**



# Population Based Incremental Learning (PBIL)

Obtener un vector de probabilidad inicial  $p_0(\mathbf{x})$

**while** no convergencia **do**  
**begin**

Usando  $p_l(\mathbf{x})$  obtener  $M$  individuos:  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Evaluar y ordenar  $\mathbf{x}'_1, \dots, \mathbf{x}'_k, \dots, \mathbf{x}'_M$

Seleccionar los  $N$  ( $N \leq M$ ) mejores individuos:  $\mathbf{x}'_{1:M}, \dots, \mathbf{x}'_{k:M}, \dots, \mathbf{x}'_{N:M}$

Actualizar el vector de probabilidades  $p_{l+1}(\mathbf{x}) = (p_{l+1}(x_1), \dots, p_{l+1}(x_n))$

**for**  $i = 1, \dots, n$  **do**

$$p_{l+1}(x_i) = (1 - \alpha)p_l(x_i) + \alpha \frac{1}{N} \sum_{k=1}^N x'_{i,k:M}$$

**end**





# Algoritmo TREE

## Características generales

- Modelo probabilístico:  $p(\mathbf{x}) = \prod_{i=1}^n p(x_i | x_{j(i)})$
- Aprendizaje estructural: algoritmo de Chow y Liu
- Aprendizaje paramétrico: máxima verosimilitud
- Muestreo: muestreo lógico probabilístico



# Algoritmo TREE

## Características generales

- Modelo probabilístico:  $p(\mathbf{x}) = \prod_{i=1}^n p(x_i | x_{j(i)})$
- Aprendizaje estructural: algoritmo de Chow y Liu
- Aprendizaje paramétrico: máxima verosimilitud
- Muestreo: muestreo lógico probabilístico

# Algoritmo TREE

## Características generales

- Modelo probabilístico:  $p(\mathbf{x}) = \prod_{i=1}^n p(x_i | x_{j(i)})$
- Aprendizaje estructural: algoritmo de Chow y Liu
- Aprendizaje paramétrico: máxima verosimilitud
- Muestreo: muestreo lógico probabilístico

# Algoritmo TREE

## Características generales



- Modelo probabilístico:  $p(\mathbf{x}) = \prod_{i=1}^n p(x_i | x_{j(i)})$
- Aprendizaje estructural: algoritmo de Chow y Liu
- Aprendizaje paramétrico: máxima verosimilitud
- Muestreo: muestreo lógico probabilístico



# Algoritmo de Chow y Liu

i) Para cada  $X_i, X_j$  calcular:



$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$



# Algoritmo de Chow y Liu

i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir







# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:

Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:  
Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:  
Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:  
Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla





# Algoritmo de Chow y Liu

- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:  
Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla
- iv) Orientar los arcos eligiendo cualquier nodo como raíz





# Algoritmo de Chow y Liu


- i) Para cada  $X_i, X_j$  calcular:

$$MI(X_i, X_j) = \sum_{x_i, x_j} p(x_i, x_j) \log \frac{p(x_i, x_j)}{p(x_i)p(x_j)}$$

- ii) Asignar las dos aristas con mayor valor de MI al árbol a construir
- iii) Repetir hasta tener  $n - 1$  aristas en el árbol:  
Asignar la arista con mayor valor de MI a menos que forme un ciclo, en dicho caso eliminarla
- iv) Orientar los arcos eligiendo cualquier nodo como raíz




# Algoritmo de Chow y Liu





# Algoritmo de Chow y Liu

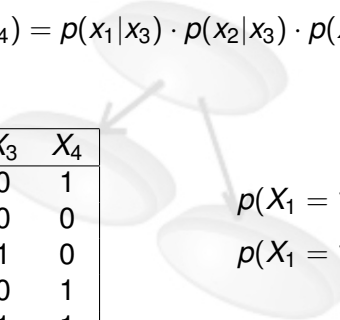


$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1


$$p(X_1 = 1|X_3 = 0)$$

$$p(X_1 = 1|X_3 = 1)$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1

$$p(X_1 = 1|X_3 = 0)$$

$$p(X_1 = 1|X_3 = 1)$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1

$$p(X_1 = 1|X_3 = 0) = \frac{2}{3}$$

$$p(X_1 = 1|X_3 = 1)$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1

$$p(X_1 = 1|X_3 = 0) = \frac{2}{3}$$

$$p(X_1 = 1|X_3 = 1)$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1

$$p(X_1 = 1|X_3 = 0) = \frac{2}{3}$$

$$p(X_1 = 1|X_3 = 1) = \frac{0}{2}$$

# Aprendizaje paramétrico en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$X_1$	$X_2$	$X_3$	$X_4$
1	0	0	1
1	1	0	0
0	1	1	0
0	0	0	1
0	1	1	1

$$p(X_1 = 1|X_3 = 0) = \frac{2 + \epsilon}{3 + 2\epsilon}$$

$$p(X_1 = 1|X_3 = 1) = \frac{0 + \epsilon}{2 + 2\epsilon}$$

# Muestreo en TREE

- Se ordenan las variables de forma que las variables padres esten antes que las variables hijo




- En nuestro caso:  $X_3, X_1, X_2, X_4$
- Se muestrean las variables en dicho orden



# Muestreo en TREE


- Se ordenan las variables de forma que las variables padres esten antes que las variables hijo



- En nuestro caso:  $X_3, X_1, X_2, X_4$
- Se muestrean las variables en dicho orden

# Muestreo en TREE


- Se ordenan las variables de forma que las variables padres esten antes que las variables hijo



- En nuestro caso:  $X_3, X_1, X_2, X_4$
- Se muestrean las variables en dicho orden

# Muestreo en TREE

- Se ordenan las variables de forma que las variables padres esten antes que las variables hijo



- En nuestro caso:  $X_3, X_1, X_2, X_4$
- Se muestrean las variables en dicho orden

# Muestreo en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$$p(X_1 = 1|X_3 = 0) = 0,3 \quad p(X_2 = 1|X_3 = 0) = 0,1 \quad p(X_3 = 1) = 0,7 \quad p(X_4 = 1|X_3 = 0) = 0,5$$

$$p(X_1 = 1|X_3 = 1) = 0,2 \quad p(X_2 = 1|X_3 = 1) = 0,8 \quad p(X_4 = 1|X_3 = 1) = 0,6$$

Orden de las variables:  $X_3, X_1, X_2, X_4$

$X_1$	$X_2$	$X_3$	$X_4$
0.85	0.55	0.23	0.91
↓	↓	↓	↓

# Muestreo en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$$p(X_1 = 1|X_3 = 0) = 0,3 \quad p(X_2 = 1|X_3 = 0) = 0,1 \quad p(X_3 = 1) = 0,7 \quad p(X_4 = 1|X_3 = 0) = 0,5$$

$$p(X_1 = 1|X_3 = 1) = 0,2 \quad p(X_2 = 1|X_3 = 1) = 0,8 \quad p(X_4 = 1|X_3 = 1) = 0,6$$

Orden de las variables:  $X_3, X_1, X_2, X_4$

$X_1$	$X_2$	$X_3$	$X_4$
0.85	0.55	0.23	0.91
↓	↓	↓	↓

1

# Muestreo en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

$$p(X_1 = 1|X_3 = 0) = 0,3 \quad p(X_2 = 1|X_3 = 0) = 0,1 \quad p(X_3 = 1) = 0,7 \quad p(X_4 = 1|X_3 = 0) = 0,5$$

$$p(X_1 = 1|X_3 = 1) = 0,2 \quad p(X_2 = 1|X_3 = 1) = 0,8 \quad p(X_4 = 1|X_3 = 1) = 0,6$$

Orden de las variables:  $X_3, X_1, X_2, X_4$

$X_1$	$X_2$	$X_3$	$X_4$
0.85	0.55	0.23	0.91
↓	↓	↓	↓
0		1	

# Muestreo en TREE

$$p(x_1, x_2, x_3, x_4) = p(x_1|x_3) \cdot p(x_2|x_3) \cdot p(x_3) \cdot p(x_4|x_3)$$

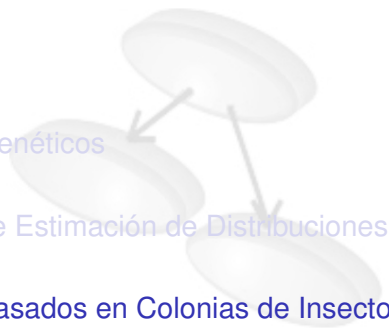
$$p(X_1 = 1|X_3 = 0) = 0,3 \quad p(X_2 = 1|X_3 = 0) = 0,1 \quad p(X_3 = 1) = 0,7 \quad p(X_4 = 1|X_3 = 0) = 0,5$$

$$p(X_1 = 1|X_3 = 1) = 0,2 \quad p(X_2 = 1|X_3 = 1) = 0,8 \quad p(X_4 = 1|X_3 = 1) = 0,6$$

Orden de las variables:  $X_3, X_1, X_2, X_4$

$X_1$	$X_2$	$X_3$	$X_4$
0.85	0.55	0.23	0.91
↓	↓	↓	↓
0	1	1	0

# Organización del tema

- 
- 1 Introducción
  - 2 Algoritmos Genéticos
  - 3 Algoritmos de Estimación de Distribuciones
  - 4 Algoritmos Basados en Colonias de Insectos**
  - 5 Búsqueda Dispersa



# Swarm Intelligence

## Características principales


- Inspirados en el comportamiento de los insectos: colonias de hormigas, enjambres, etc..
- Individuos con capacidades limitadas resuelven en grupo problemas muy complejos
- La adaptación para la resolución de problemas de optimización no es trivial




# Algoritmo basado en colonias de hormigas




# Algoritmo basado en colonias de hormigas



# Algoritmo basado en colonias de hormigas



# Algoritmo basado en colonias de hormigas



# ACH aplicado al TSP

## Aspectos generales

- Disponemos inicialmente una hormiga en cada ciudad
- A cada paso cada hormiga elige una ciudad no visitada anteriormente
- Tras  $n$  pasos todas las hormigas han completado una ruta
- Se procede a la modificación de la feromona

# ACH aplicado al TSP

## Método constructivo

- A cada paso se elige una ciudad
- ¿Cómo se elige la ciudad?

$$p_{ij}^k = \frac{\tau_{ij}^\alpha \cdot \eta_{ij}^\beta}{\sum_{l \in \mathcal{N}_i^k} \tau_{il}^\alpha \cdot \eta_{il}^\beta} \quad \text{si } j \in \mathcal{N}_i^k$$

probabilidad de que la  $k$ -ésima hormiga situada en la ciudad  $i$ -ésima elija la  $j$ -ésima ciudad



# ACH aplicado al TSP

## Método constructivo

$$p_{ij}^k = \frac{\tau_{ij}^{\alpha} \cdot \eta_{ij}^{\beta}}{\sum_{l \in \mathcal{N}_i^k} \tau_{il}^{\alpha} \cdot \eta_{il}^{\beta}} \quad \text{si } j \in \mathcal{N}_i^k$$

- $\tau_{ij}$  es la feromona depositada entre las ciudades  $(i, j)$
- $\eta_{ij}$  es el valor del heurístico entre las ciudades  $(i, j)$
- $\mathcal{N}_i^k$  ciudades a las que puede ir la hormiga  $k$ -ésima que se encuentra en la ciudad  $i$ -ésima
- $\alpha$  y  $\beta$  son parámetros del algoritmo





# ACH aplicado al TSP

## Método constructivo

$$p_{ij}^k = \frac{\tau_{ij}^\alpha \cdot \eta_{ij}^\beta}{\sum_{l \in \mathcal{N}_i^k} \tau_{il}^\alpha \cdot \eta_{il}^\beta} \quad \text{si } j \in \mathcal{N}_i^k$$

- Posible valor para  $\eta_{ij} = \frac{1}{d_{ij}}$
- Si  $\alpha = 0$ , el algoritmo es equivalente a un algoritmo greedy aleatorio
- Si  $\beta = 0$ , solo se tiene en cuenta la feromona, el algoritmo converge rápidamente a una mala solución
- Sería posible utilizar un único parámetro mezclando ambos



# ACH aplicado al TSP

## Modificación de la feromona

- Disipación de la feromona  $\tau_{ij} \leftarrow (1 - \rho)\tau_{ij} \quad (0 < \rho < 1)$
- Incremento de feromona:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^m \Delta\tau_{ij}^k \quad \forall(i, j)$$

donde

$$\Delta\tau_{ij}^k = \begin{cases} \frac{1}{C^k} & \text{si el arco } (i, j) \text{ está en } T^k \\ 0 & \text{en otro caso} \end{cases}$$

siendo  $T^k$  la ruta de la hormiga  $k$ -ésima



# ACH aplicado al TSP. Mejoras

## Modelo elitista

- Se incrementa la feromona de los arcos en la mejor ruta encontrada hasta la fecha  $T^{bs}$ :

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^m \Delta\tau_{ij}^k + e\Delta\tau_{ij}^{bs} \quad \forall(i,j)$$

con

$$\Delta\tau_{ij}^{bs} = \begin{cases} \frac{1}{C^{bs}} & \text{si el arco } (i,j) \text{ está en } T^{bs} \\ 0 & \text{en otro caso} \end{cases}$$

donde  $e$  es un nuevo parámetro



# ACH aplicado al TSP. Mejoras

## Modelo basado en ranking


- Cada hormiga deposita una cantidad de feromona que decrece con su ranking

## Modelo Max-Min

- Sólo se utiliza la mejor ruta de cada iteración y la mejor globalmente para modificar la feromona
- La feromona se encuentra en un rango  $[\tau_{min}, \tau_{max}]$



# Organización del tema

- 
- 1 Introducción
  - 2 Algoritmos Genéticos
  - 3 Algoritmos de Estimación de Distribuciones
  - 4 Algoritmos Basados en Colonias de Insectos
  - 5 Búsqueda Dispersa**

