

Máster Universitario en
Ingeniería Computacional y
Sistemas Inteligentes



eman ta zabal zazu




Universidad
del País Vasco

Euskal Herriko
Unibertsitatea

MODELADO PROBABILÍSTICO

De los datos al modelo

BORJA CALVO • borja.calvo@ehu.es



Modelos paramétricos


- PASO 1 – Escoger una familia de distribuciones de probabilidad
 - Definidas en un dominio apropiado
 - Forma apropiada para la variable a modelar
- PASO 2 – **Estimar los parámetros** de la distribución a partir de los datos



Método de los momentos

$$\mu'_k = E[X^k] = m'_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

$$\mu_k = E[(X - \mu'_1)^k] = m_k = \frac{1}{n} \sum_{i=1}^n (x_i - m'_1)^k$$





Método de máxima verosimilitud

(2, 1, 1, 2, 3, 3, 1, 2, 4, 2, 5, 3, 1, 2, 4, 3, 0, 2, 2, 0)

Queremos modelar la variable con una distribución de Poisson. ¿Con qué valor del parámetro λ son los datos más “creíbles”?

$$\hat{\lambda} = \max_{\lambda} \prod_{i=1}^n \left(\frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \right)$$





Método de máxima verosimilitud

Supongamos una variable que sigue una distribución de Bernoulli de parámetro p

$$\hat{p} = \max_p \prod_{i=1}^n P(X = x_i) = \max_p (p^{n_1} (1-p)^{n_0}) = \frac{n_1}{n}$$

Si en la muestra no hay observaciones de un valor, entonces la estimación es 0

Para evitar esto: corrección de Laplace

$$\hat{p} = \frac{n_1 + 1}{n + 2}$$

En el caso de la multinomial:

$$\hat{p}_i = \frac{n_i + 1}{n + r}$$



La regla de Bayes nos permite determinar la probabilidad de los parámetros dados los datos

$$P(\boldsymbol{\theta}|D) = \frac{P(D|\boldsymbol{\theta})P(\boldsymbol{\theta})}{P(D)}$$

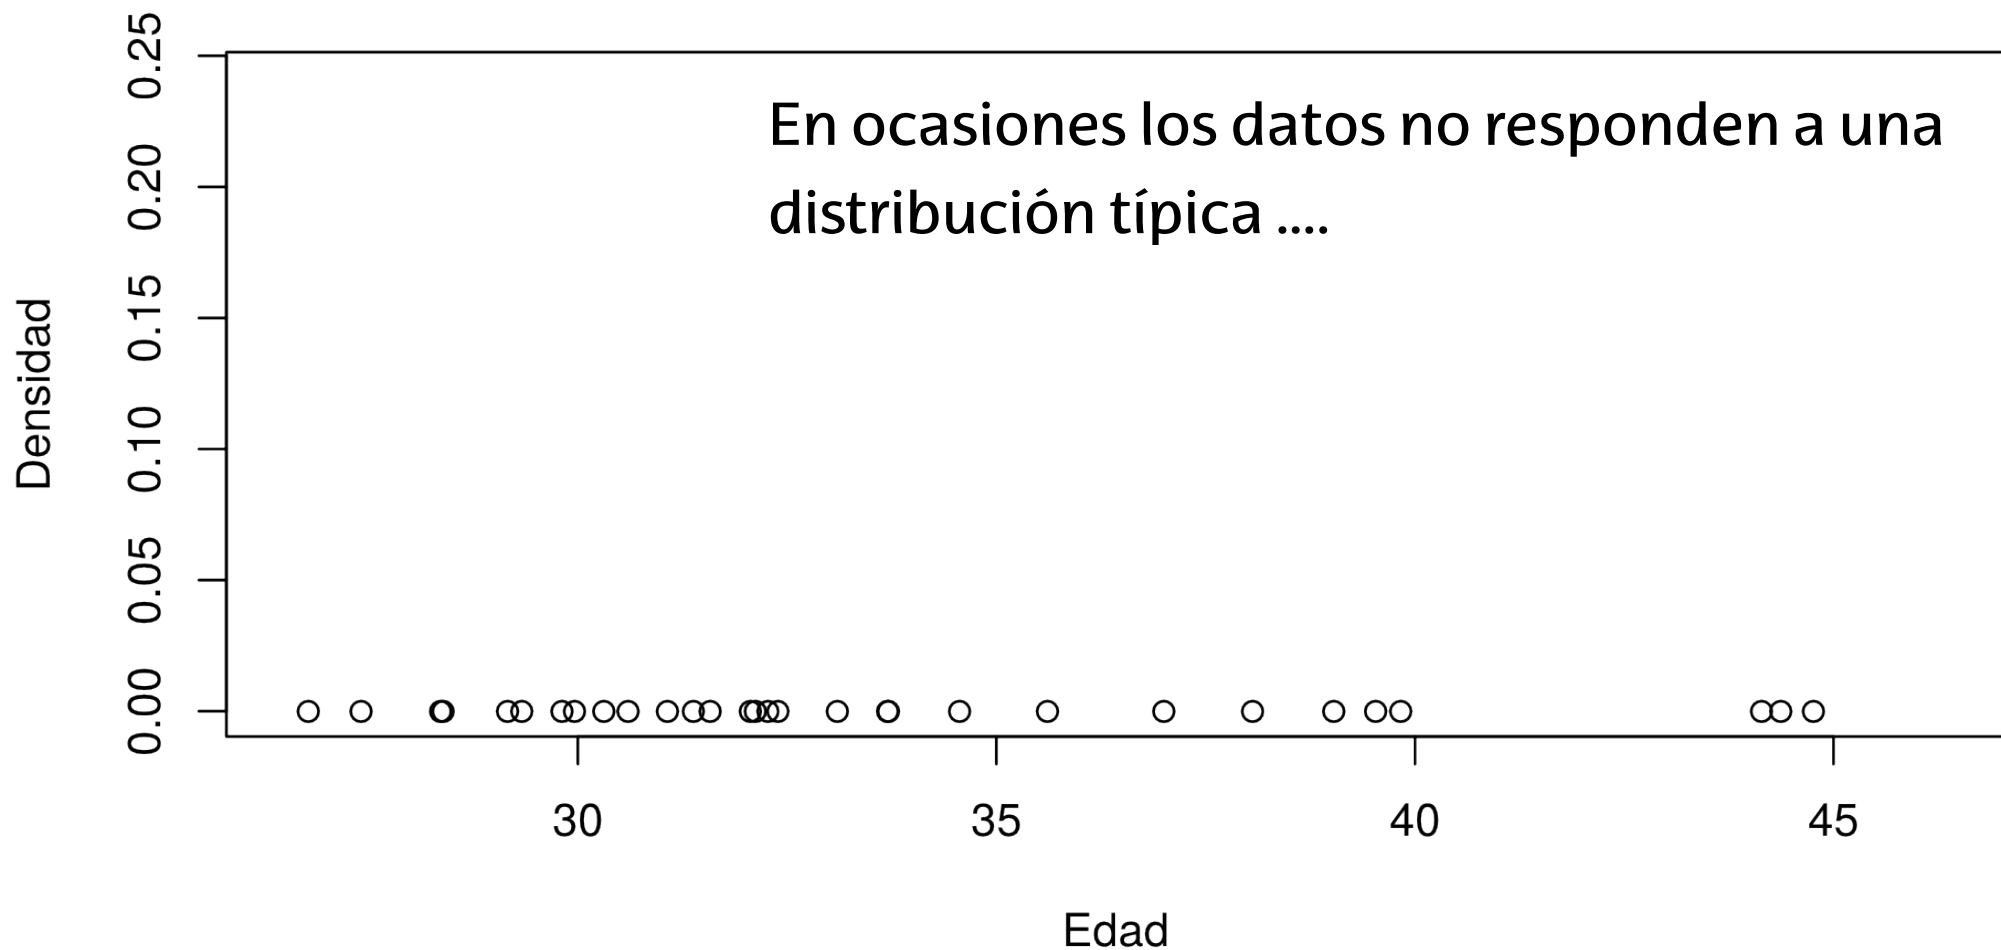
El estimador Bayesiano se define como:


$$E[\boldsymbol{\theta}|D] = \int P(\boldsymbol{\theta}|D) d\boldsymbol{\theta}$$

Modelos semi-paramétricos




Mixturas de distribuciones








Mixturas de distribuciones




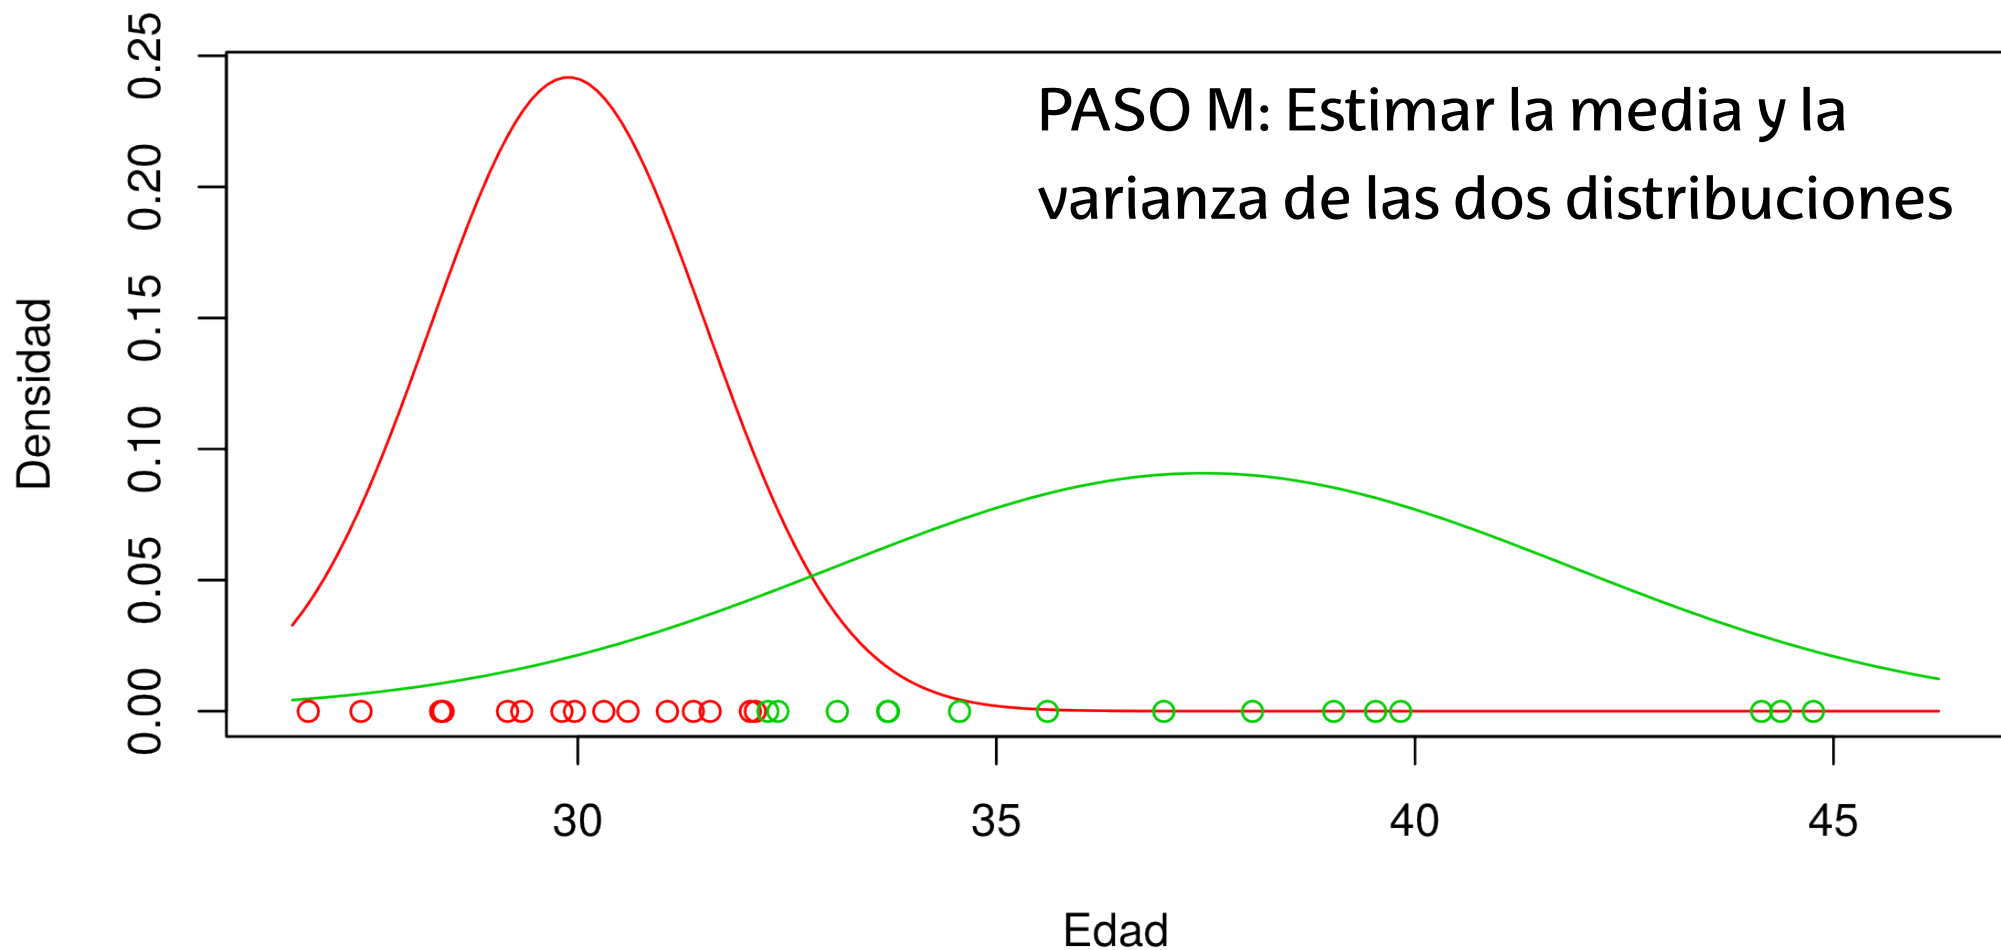




ALGORITMO EXPECTATION-MAXIMIZATION


- 1) INICIALIZACIÓN: Asignar cada muestra a una componente de la mixtura (ordenar y repartir equitativamente, por ejemplo)
- 2) MIENTRAS (haya cambio en la asignación)
 - 1) Paso M: Con las muestras asignadas a cada distribución, estimar los parámetros
 - 2) Paso E: Revisar la asignación, asignando cada muestra a la componente en la que tenga una mayor probabilidad








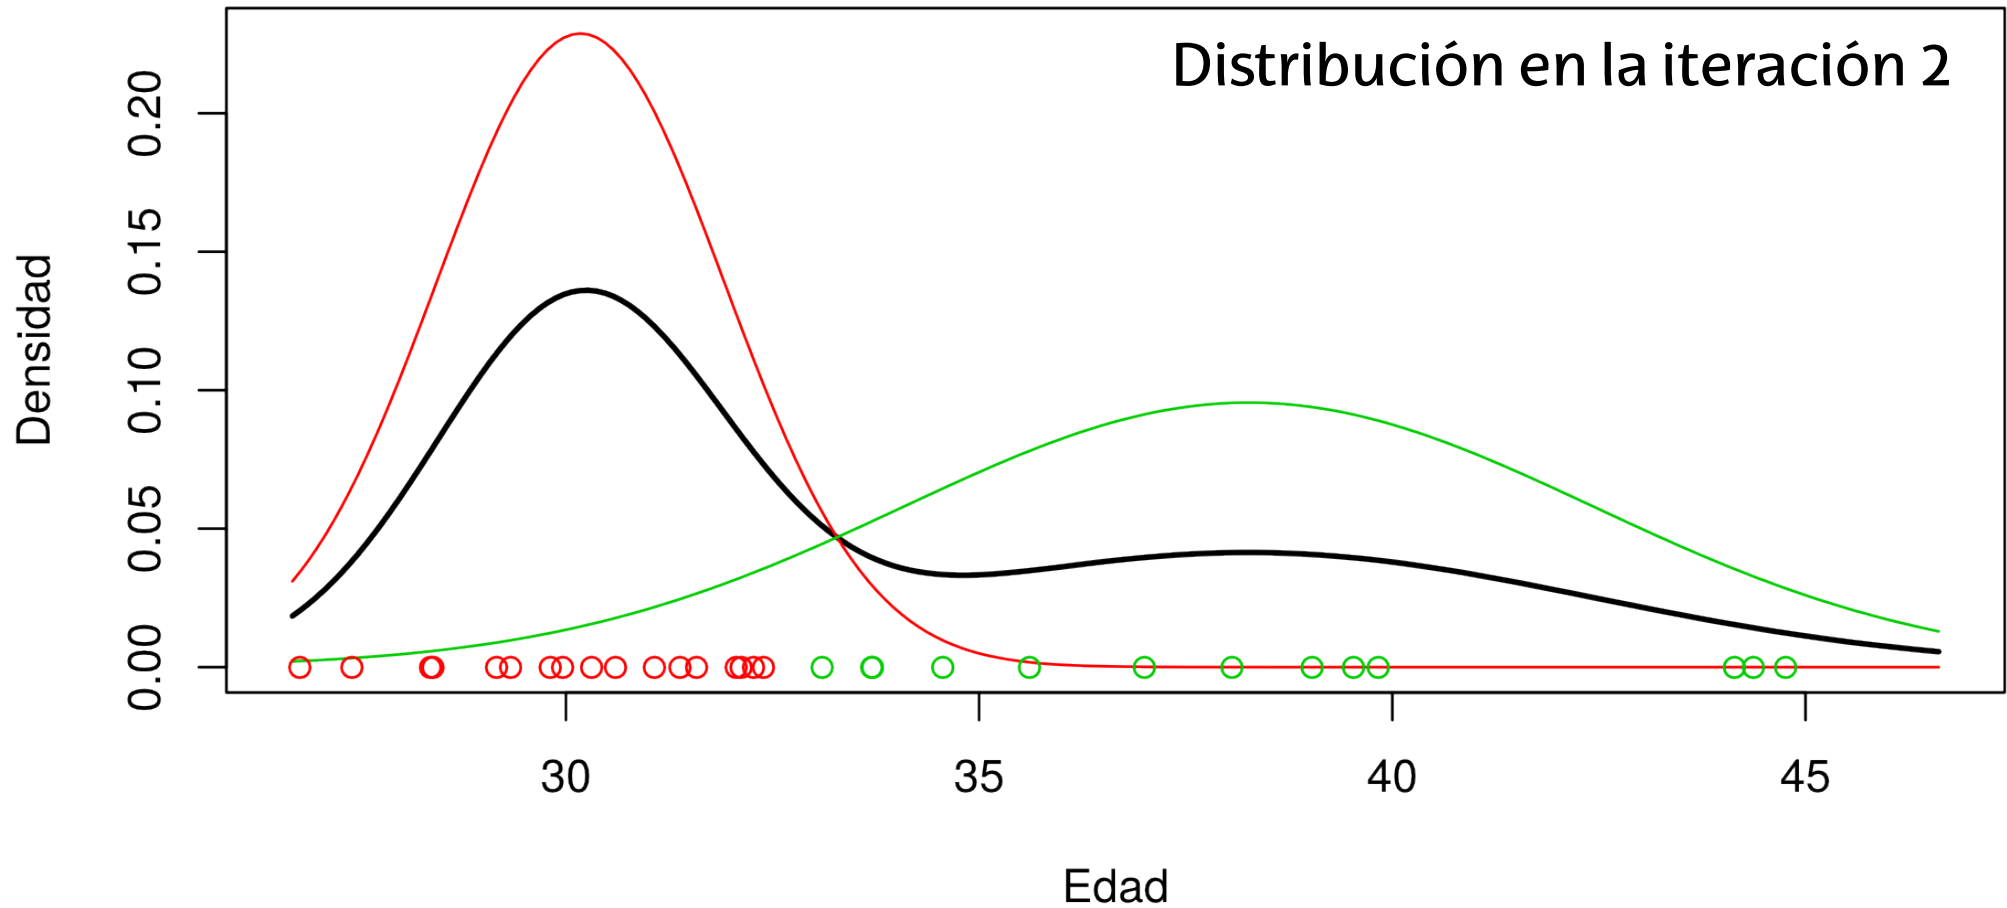
Mixturas de distribuciones





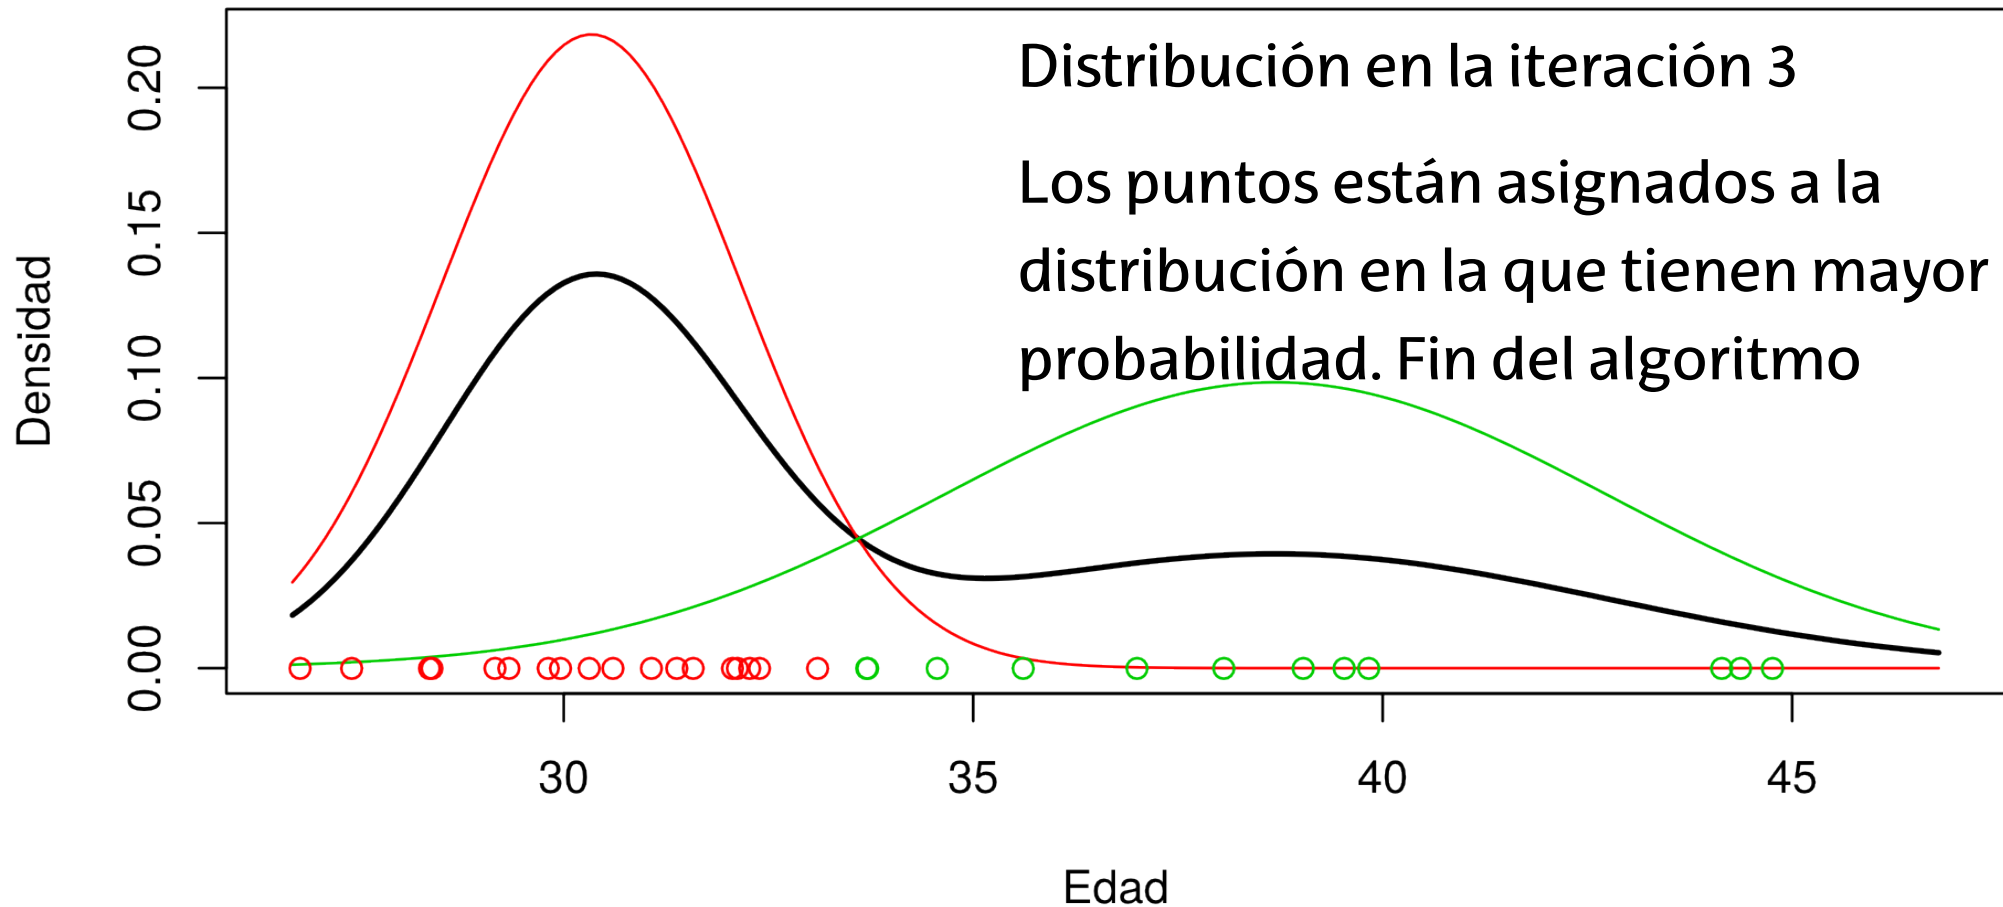


Mixturas de distribuciones







Mixturas de distribuciones




Modelos no paramétricos





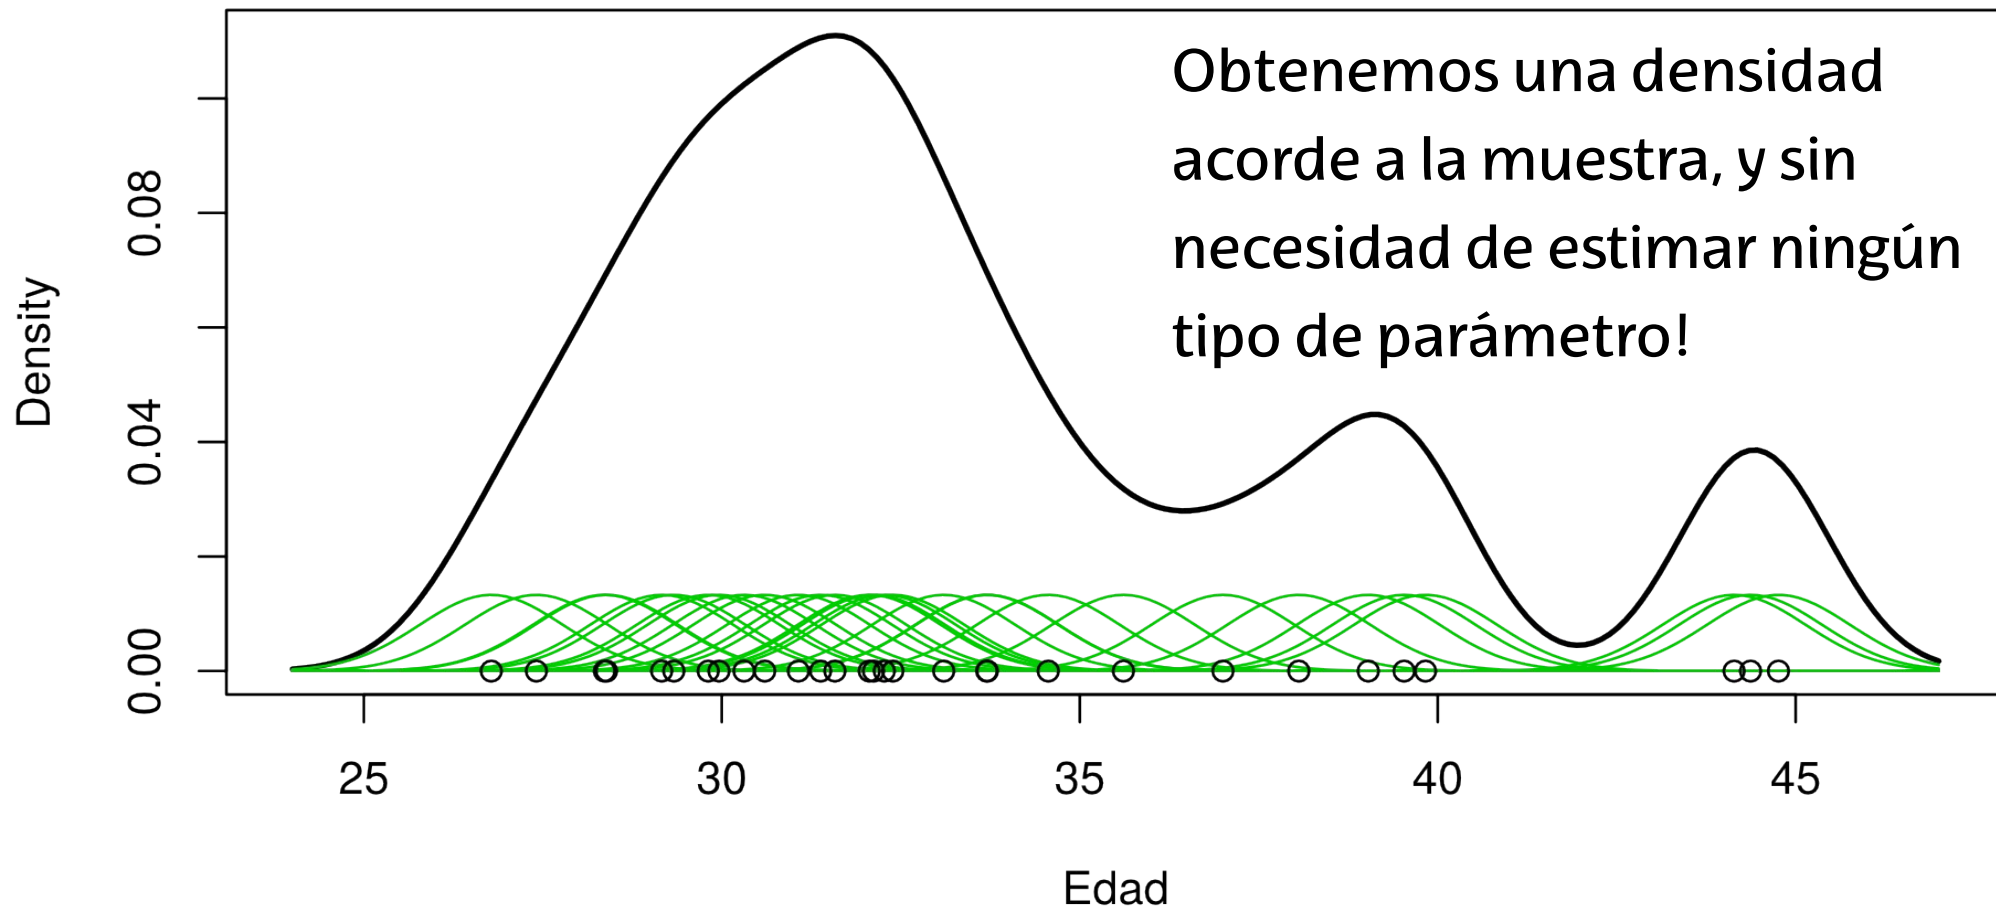


Estimación basada en kernels



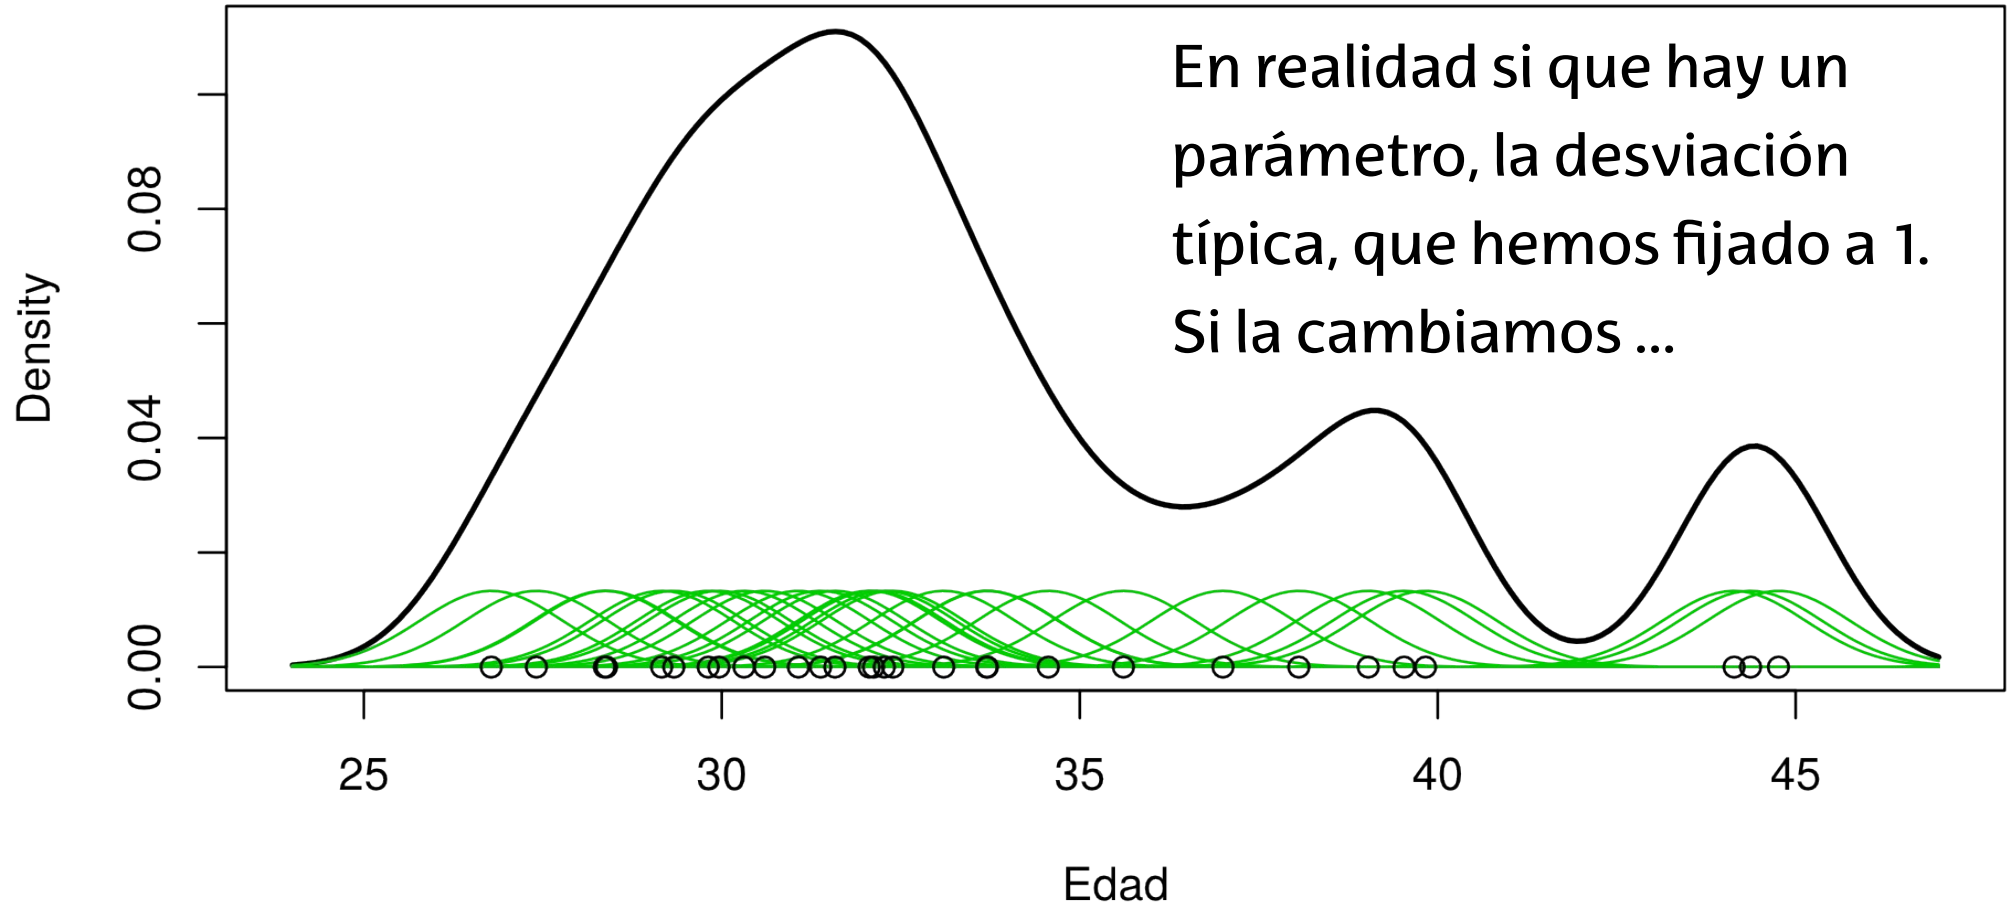


Estimación basada en kernels



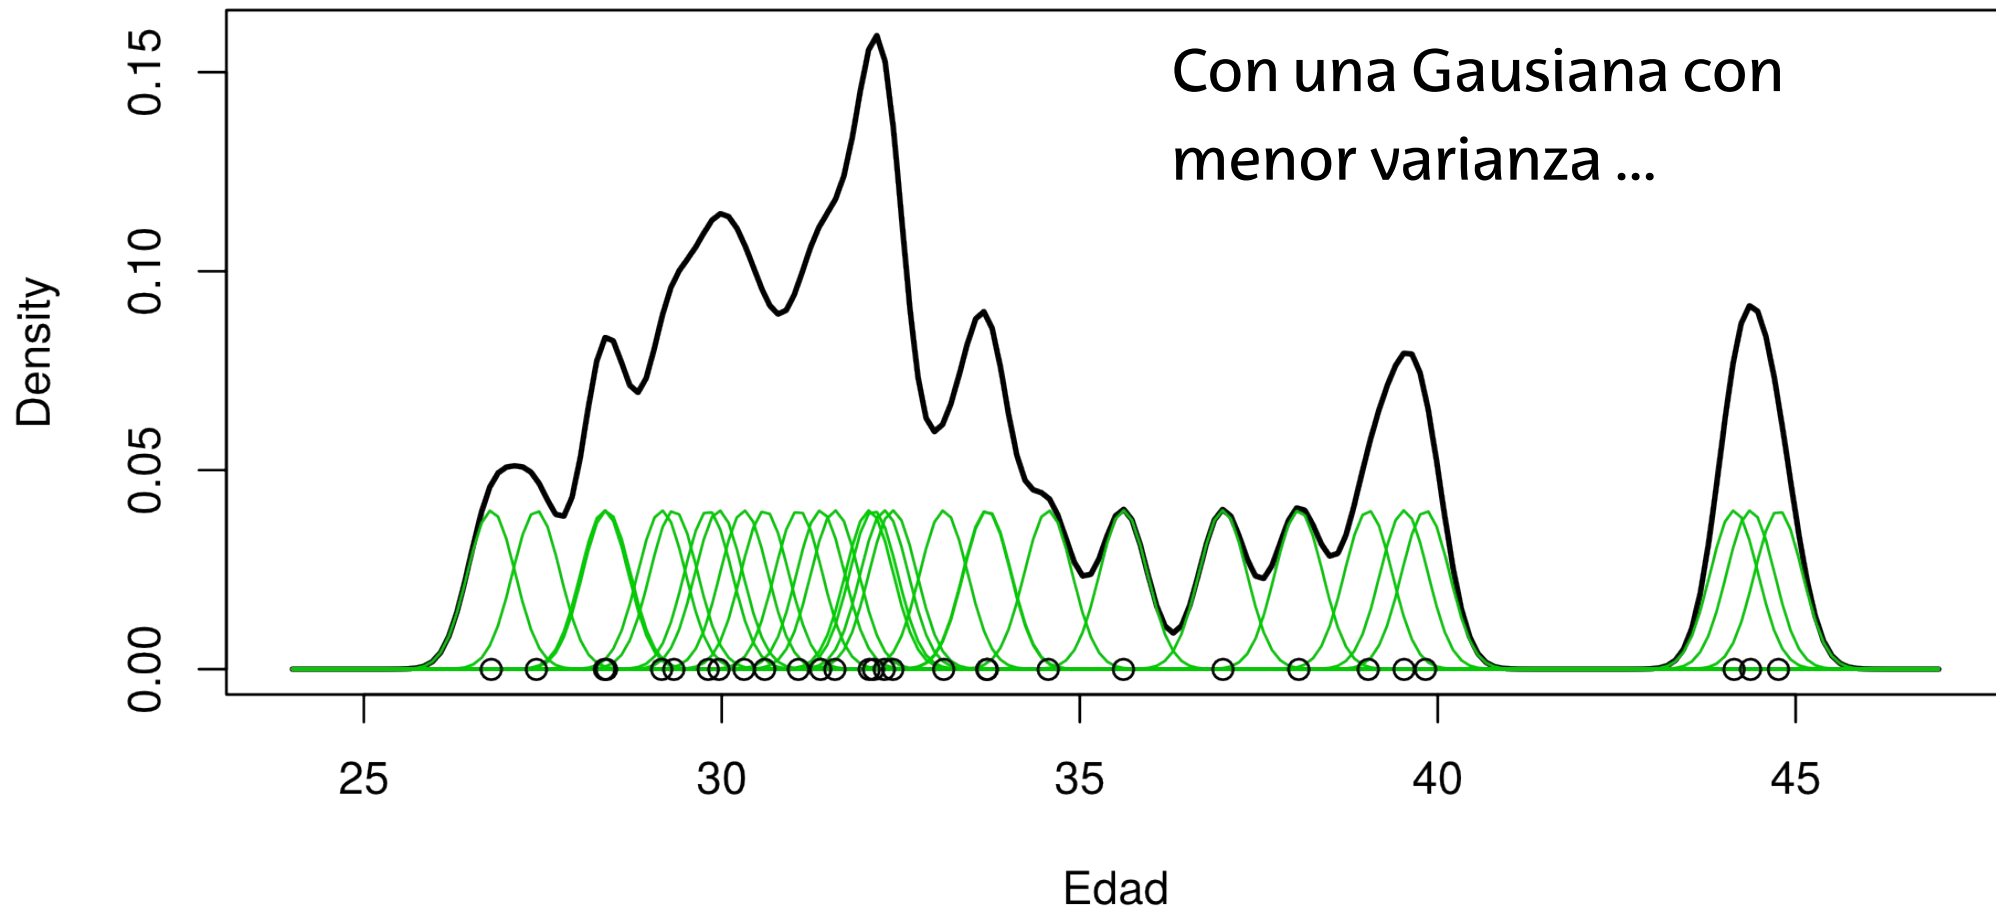


Estimación basada en kernels






Estimación basada en kernels





Estimación basada en kernels





Esta es la idea detrás de la *estimación basada en kernels (KDE)*

$$f(x; b) = \frac{1}{n} \sum_{i=1}^n K(x; X_i, b)$$

En el ejemplo la función K es una distribución Gausiana de media X_i y desviación típica b , pero puede ser cualquier otra función, siempre y cuando cumpla estas tres propiedades:

$$\int_x K(x; X_i, b) dx = 1; \int_x x K(x; X_i, b) dx = 0; \int_x x^2 K(x; X_i, b) dx > 0$$

El parámetro b (a veces también llamado h) es el *ancho de banda o parámetro de suavizado* del estimador.

